

AI 使用说明

1. 使用的 AI 工具

工具	版本或环境信息	主要用途
OpenAI Codex 桌面应用	本机 Codex 运行时 bundle version: 26.622.11653; WindowsApps 安装包路径显示版本: OpenAI.Codex_26.616.10790.0	辅助规划、生成、修改和检查 Jupyter Notebook
OpenAI GPT-5	Codex 当前会话使用的模型: GPT-5	辅助理解考试要求、整理分析逻辑、生成代码、检查结论一致性和优化中文说明
Python 环境	D:\minianaconda\envs\shujufenxikeshihua	执行 Notebook、调用 pandas/numpy/seaborn/matplotlib/plotly, 并用 nbclient 验证运行结果

2. 使用 AI 的具体环节

阶段	具体用途	AI 辅助内容	我做的检查或修改
任务理解	解读正式考试说明和模板要求	梳理 Notebook 必须包含摘要、读取、清洗、统计、可视化、结论和 AI 使用说明	确认模板中“福州二手房数据分析”之前的内容不得修改
数据读取	正确读取 ershoufang_list.csv	辅助编写 pd.read_csv(..., encoding='utf-8-sig') 和基础查看代码	确认数据为 11856 行、18 列, 字段读取正常; 将前 5 行样例展示放在“数据基本情况”部分
字段理解	说明字段含义和分析目标	辅助整理 id、市区、标题、户型、面积、楼层、时间、总价、均价 等字段含义	补充了计划围绕区域、价格、户型、房龄、关键词和异常值处理展开分析
文本清洗	从原始文本字段提取数值	辅助从 面积、总价、均价、时间、楼层、户型 中提取变量	对比原表 面积数值、总价数值、均价数值, 确认提取结果一致; 将文本字段样例改为 DataFrame 展示
缺失值处理	明确缺失值处理策略	辅助统计缺失值并说明总价/均价缺失不填充、不整行删除	确认价格缺失样本只在价格相关分析中排除, 非价格分析仍保留
重复值检查	解释完全重复、链接重复和近似重复	辅助检查完全重复行、房源链接重复、关键字段近似重复	确认完全重复和链接重复为 0; 关键字段近似重复不机械删除, 并补充 Markdown 说明原因
极			

端 值 处 理	识别并解释高价、大面积样本	辅助使用 IQR 检测面积、总价、均价等可能极端值	查看高总价、高均价房源，判断其多为真实豪宅、别墅或改善型房源，不机械删除
主 流 住 宅 样 本	定义用于图表展示的普通市场子集	辅助根据数据分布和业务含义设定面积、总价、均价、室数范围	解释主流住宅样本不是删除数据，只用于降低豪宅/别墅对图表主体分布的影响；修正 5 室及以上箱型图缺失问题
统 计 分 析	完成分组统计和交叉分析	辅助按市区、户型、房龄、板块、小区和标题关键词统计价格差异	检查统计口径，避免小样本板块误导结论，并补充各统计结果的二手房实际含义
可 视 化	绘制静态和交互式图表	辅助使用 seaborn/matplotlib/plotly 生成柱状图、箱线图、散点图、热力图、树图	调整中文字体、坐标轴、单位、颜色和图表尺寸；将图表标题移动到图片下方
图 表 解 释 修 正	检查图表结论是否准确	辅助检查图 6 热力图和图 7 交互散点图解释	修正图 6 中相关性解释，说明总价与均价存在计算关系；补充图 7 固定随机抽样原因和可得到的结论
结 论 整 理	形成有数据支持的结论	辅助将统计表和图表发现整理为中文结论	删除没有数据支撑的表述，保留可由 Notebook 输出验证的结论，并将“主要结论”改为 Markdown
摘 要 修 改	根据全文最终分析更新摘要	辅助检查摘要和全文结论是否一致	基于最终统计结果重写摘要中的主要结论，避免与后文数据不一致
运 行 验 证	确保 Notebook 可提交	辅助使用 <code>nbcclient</code> 从头到尾执行 Notebook	检查无 error 输出，图表和表格结果已保留

3. 主要提问内容或提示词摘要

1. 请根据正式考试说明和模板，对福州二手房 CSV 数据进行数据分析和可视化。
2. 模板中“福州二手房数据分析”之前的内容不要改动，后续内容可调整和补充。
3. 优先从原始文本字段清洗，如面积、总价、均价、时间、楼层、户型等。
4. 需要结合数据含义说明异常值和缺失值的处理方式及原因。
5. 使用中文 Markdown、中文代码注释和中文图表标题，注意防止中文乱码。
6. 使用 `shujufenxikeshihua` 环境生成并运行 Notebook，保留运行结果。
7. 可视化图表要突出数据特点，不同图表不要重复同一信息，可适当使用交互式图表。

8. 补充数据质量检查的文字总结，解释缺失值、重复值和关键字段近似重复。
9. 补充描述性统计结果的文字解释，围绕二手房市场实际意义说明发现。
10. 将第 8 节主要结论改为 Markdown，不使用 Python 代码动态生成。
11. 将第 2 节补充字段含义和分析问题，并把前 5 行数据展示移到第 3 节。
12. 将文本字段样例输出改为 DataFrame 格式。
13. 解释主流住宅样本的定义依据，并修正 5 室及以上箱型图缺失问题。
14. 将图表标题放在图片下方，修正图表中文显示和图 7 点重叠问题。
15. 检查图 6 热力图结论是否有问题，补充图 7 固定随机抽样原因和图表结论。
16. 检查 Markdown 说明、Python 运行结果和第 8 节主要结论是否一致，并基于全文修改第 1 节摘要。

4. 我对 AI 输出做了哪些检查、修改或取舍

1. 检查模板结构，确认只替换 `# 福州二手房数据分析` 之后的内容。
2. 检查 CSV 字段、样例数据和缺失值，确认主要缺失集中在总价和均价相关字段。
3. 从原始文本字段重新提取数值，并与已有数值字段核对，避免直接依赖现成整理结果。
4. 将文本字段样例从逐列 `print` 改成 DataFrame 展示，使 Notebook 输出更整齐。
5. 没有采纳简单删除价格缺失记录的做法，因为这些记录仍可用于非价格分析。
6. 没有采纳简单删除高价、大面积房源的做法，因为这些样本多为真实豪宅、别墅或改善型房源。
7. 对关键字段近似重复 1655 条没有直接删除，因为二手房平台中可能存在同小区相似户型、相近挂牌房源或标题相似记录。
8. 构造主流住宅样本只用于辅助展示普通市场，不代表从原始数据中删除极端房源。
9. 根据数据分布和业务含义修正主流住宅样本范围，使 `5室及以上` 中的普通大户型也能进入户型图表。
10. 检查图表主题，确保各图分别表达房源数量、价格分布、面积总价关系、户型、房龄、相关性和板块结构。
11. 修改图表排版，将静态图和交互图的标题放在图片下方。
12. 检查图 6 热力图解释，修正“均价与总价相关”容易被误解为单一因果的问题。
13. 检查图 7 散点图，采用固定随机抽样、缩小点大小和降低透明度，改善重叠问题。
14. 检查第 8 节主要结论是否都能从前文统计表或图表中找到依据。
15. 根据最终结论重写摘要，保证摘要、正文和主要结论一致。
16. 使用 `nbclient` 多次执行 Notebook，确认代码可从头到尾运行并保留结果。

5. 哪些分析结论是我根据数据自行判断得到的

1. 房源供应主要集中在晋安区和仓山区，其中价格非缺失样本中晋安区 4346 条、仓山区 3926 条。
2. 不同市区的均价分布存在明显差异，鼓楼区均价中位数约 22973 元/平方米，罗源县约 5103 元/平方米。
3. 3 室房源是样本中的主流户型，共 7183 条，中位总价约 175 万元，符合家庭型居住需求。
4. 面积和总价整体呈正相关，相关系数约 0.64；但面积与均价相关性较弱，说明单价更多受区位、板块、小区品质、房龄等因素影响。
5. 均价与总价相关系数较高，但由于总价约等于面积乘以均价，不能简单理解为均价单独决定总价。

6. 房龄与均价不是简单线性关系，老房源如果位于核心城区也可能保持较高单价。
7. 鼓楼五四路等核心板块均价较高，说明板块层级比单纯市区维度更能体现价格分化。
8. 标题中包含“学区”相关词的房源均价中位数更高，但这只能说明标题卖点与价格有关，不能直接证明因果关系。
9. 高总价、高均价、大面积样本多数属于真实高端房源，不应简单视为错误数据。
10. 总价和均价缺失样本不适合用均值填充，价格相关分析应使用非缺失样本。

6. AI 辅助边界说明

AI 主要用于辅助整理思路、编写代码框架、解释处理策略、优化图表代码和改进中文表达。最终保留的清洗方式、异常值处理、图表选择、摘要和主要结论，均根据 Notebook 实际运行结果进行检查和修改后确定。对于缺失值、近似重复、主流住宅样本定义、热力图相关性解释和交互散点图抽样展示等关键内容，我结合数据结果和二手房业务含义进行了判断，没有直接照搬 AI 输出。